Titulación: **Grado en Ingeniería Informática, Ingeniería en Sistemas de Información e InfoAde**

Curso: **2025-2026. Convocatoria Ordinaria de Mayo**

Asignatura: **Bases de Datos Avanzadas – Laboratorio**

Practica 2: Carga Masiva de Datos, Procesamiento y Optimización de Consultas

ALUMNO 1:

Nombre y Apellidos: Jorge Lopez Duque

DNI: 70943373B

ALUMNO 2:

Nombre y Apellidos: José Antonio López González

DNI: 03209889D

Fecha: 19/04/2026

Profesor Responsable: Javier Arrollo Gallardo

Mediante la entrega de este fichero los alumnos aseguran que cumplen con la normativa de autoría de trabajos de la Universidad de Alcalá, y declaran éste como un trabajo original y propio.

En caso de ser detectada copia, se calificará la asignatura como Suspenso – Cero.

Plazos

Tarea en Laboratorio:	Semana 9 de marzo, Semana 16 de marzo, Semana 23 de marzo, semana 7 de abril y 13 de abril.
Entrega de práctica:	Día 19 de abril, domingo a las 23:59. Aula Virtual
Documento a entregar:	Este mismo fichero con las respuestas a las cuestiones planteadas, el programa que genera los datos de carga de la base de datos, los ficheros de log de PostgreSQL de esta práctica. No se piden los ficheros de los datos en bruto de la base de datos. Se entregará en un ZIP comprimido llamado: **`DNI'sdelosAlumnos_PECL2.zip`**

AMBOS ALUMNOS DEBEN ENTREGAR EL FICHERO EN LA PLATAFORMA.

Introducción

El contenido de esta práctica versa sobre la monitorización de la base de datos, manipulación de datos, técnicas para una correcta gestión de los mismos, así como tareas de mantenimiento relacionadas con el acceso y gestión de los datos. También se trata el tema de procesamiento y optimización de consultas realizadas por PostgreSQL (18.1). Se analizará PostgreSQL en el proceso de carga masiva y optimización de consultas.

En general, la monitorización de la base de datos es de vital importancia para la correcta implantación de una base de datos, y se suele utilizar en distintos entornos:

- Depuración de aplicaciones: cuando se desarrollan aplicaciones empresariales no se suele acceder a la base de datos a bajo nivel, sino que se utilizan librerías de alto nivel y mapeadores ORM (Hibernate, Spring Data, MyBatis…) que se encargan de crear y ejecutar consultas para que el programador pueda realizar su trabajo más rápido. El problema en estos entornos está en que se pierde el control de qué están haciendo las librerías en la base de datos, cuántas consultas ejecutan, y con qué parámetros, por lo que la monitorización en estos entornos es vital para saber qué consultas se están realizando y poder optimizar la base de datos y los programas en función de los resultados obtenidos.
- Entornos de prueba y test de rendimiento: cuando una base de datos ha sido diseñada y se le cargan datos de prueba, una de las primeras tareas a realizar es probar que todos los datos que almacenan son consistentes y que las estructuras de datos dan un rendimiento adecuado a la carga esperada. Para ello se desarrollan programas que simulen la ejecución de aquellas consultas que se consideren de interés para evaluar el tiempo que le lleva a la base de datos devolver los resultados, de cara a buscar optimizaciones, tanto en la estructura de la base de datos como en las propias consultas a realizar.
- Monitorización pasiva/activa en producción: una vez la base de datos ha superado las pruebas y entra en producción, el principal trabajo del administrador de base de datos es mantener la monitorización pasiva de la base de datos. Mediante esta monitorización el administrador verifica que los parámetros de operación de la base de datos se mantienen dentro de lo esperado (pasivo), y en caso de que algún parámetro salga de estos parámetros ejecuta acciones correctoras (reactivo). Así mismo, el administrador puede evaluar nuevas maneras de acceso para mejorar aquellos procesos y tiempos de ejecución que, pese a estar dentro de los parámetros, muestren una desviación tal que puedan suponer un problema en el futuro (activo).

Para la realización de esta práctica será necesario generar una muestra de datos de cierta índole en cuanto a su volumen. Para ello se generarán, dependiendo del modelo de datos suministrado de una base de datos **MUSICOS**. Básicamente, la base de datos guarda los músicos que pertenecen a grupos musicales, así como los conciertos, discos y canciones que tocan. Además, se almacenan las entradas que se venden para sus conciertos (más información en la lógica de negocio del Aula Virtual). Los datos referidos al año 2025 que hay que generar deben de ser los siguientes:

- 1.000.000 de Discos donde el género musical puede ser clásica, blues, jazz, rock&roll, góspel, soul, rock, metal, funk, disco, techno, pop, reggae, hiphop, salsa. La distribución del campo género musical debe ser aleatoria entre esos valores.
- Cada disco tiene de media 12 canciones con duración de canciones que van entre los 2 minutos y los 7 minutos.
- Hay 24.000.000 de entradas distribuidas de una manera aleatoria entre todos los conciertos y el precio oscila entre 20 y 100 euros de una manera aleatoria.
- Hay 100.000 conciertos en marcha y se realizan entre 20 países donde uno de ellos debe de ser obligatoriamente España. Distribución aleatoria.
- Hay 1.000.000 de músicos.
- Hay 200.000 grupos donde cada uno de ellos debe tener entre 1 y 10 músicos.
- Todos los grupos han realizado por lo menos 10 conciertos y todos los conciertos deben de estar asociados por lo menos a 1 grupo musical.

Actividades y Cuestiones

Cuestión 0: Configurar el fichero de Error Reporting and Logging de PostgreSQL para que aparezcan recogidas las sentencias SQL DDL (Lenguaje de Definición de Datos) + DML (Lenguaje de Manipulación de Datos) generadas en dicho fichero. No se pide activar todas las sentencias. No activar la duración de la consulta. También se debe de configurar el log para que en el comienzo de la línea de registro de la información del log ("line prefix") aparezca el DNI de los alumnos que realizan la práctica (ambos), el nombre del host con su puerto, y la fecha y hora de la operación que se ha realizado. Se ha de configurar también el servidor para que no use el procesamiento paralelo de consultas.

Hemos hecho los sigueintes cambios en el fichero postgresql.conf:

-log_statement = 'mod' (Ya se habia configurado asi en la anterior practica) -> registro DDL y DML

-log_duration = off (Ya se encontraba asi) -> no registrar duracion de ejcucion

-log_min_duration_statement = -1 (Ya se encontraba asi) -> no registrar duracion de ejcucion

-log_line_prefix = '70943373B_03209889D | %r | %t | %u | %d | ' -> Comienzo del registro

-max_parallel_workers_per_gather = 0 (Antes 2) -> Desactivar procesamiento paralelo de consultas

(Hay que quitar # de todos)

Con esta configuración se registran las sentencias DDL y DML, no se registran consultas SELECT ni la duración de las consultas y el log incluye nuestros DNIs, host, puerto y fecha/hora.

A parte hemos desactivado el procesamiento paralelo del servidor.

Cuestión 1: ¿Tiene el servidor postgres un recolector de estadísticas sobre los datos de cada campo de las tablas? Si es así, ¿Qué tipos de estadísticas se recolectan y dónde se guardan?

Sí, PostgreSQL dispone de un recolector de estadísticas que analiza las tablas y columnas para ayudar al optimizador de consultas.

Estas estadísticas incluyen:
-número de valores distintos
-valores más frecuentes
-histogramas de distribución
-porcentaje de valores nulos
-tamaño medio de datos
-etc

Las estadísticas se generan mediante ANALYZE, y se almacenan en el catálogo del sistema, principalmente en pg_statistic, siendo accesibles mediante la vista pg_stats.

(Ya hemos empleado esto en la anterior practica para poder sacar estadisticas especificas de las tablas que haciamos en las cuestiones).

Cuestión 2: Crear una nueva base de datos llamada **matriculas** y que tenga las siguientes tablas con los siguientes campos y características:

- estudiantes(carnet tipo numeric PRIMARY KEY, nombre tipo text, apellidos tipo text, creditos tipo numeric)
- asignaturas(codigo tipo numeric PRIMARY KEY, nombre tipo text, caracter tipo text, creditos tipo numeric)
- matriculas(carnet_estu tipo numeric que sea FOREIGN KEY del campo carnet de la tabla estudiantes con restricciones de tipo RESTRICT en sus operaciones, codigo_asig tipo numeric que sea FOREIGN KEY del campo codigo de la tabla asignaturas con restricciones de tipo RESTRICT en sus operaciones, nota de tipo numeric. La PRIMARY KEY debe ser compuesta de carnet_estu y codigo_asig.

Se pide:

- Indicar el proceso seguido para generar esta base de datos.
- Cargar la información del fichero datos_empleados.csv, datos_proyectos.csv y datos_trabaja_proyectos.csv en dichas tablas de tal manera que sea lo más eficiente posible.
- Indicar los tiempos de carga.

El proceso seguido para generar la base de datos ha sido el siguiente:

```
--Tabla estudiantes:
CREATE TABLE estudiantes(
   carnet NUMERIC PRIMARY KEY,
   nombre TEXT,
   apellidos TEXT,
   creditos NUMERIC
);

--Tabla asignaturas:
CREATE TABLE asignaturas(
   codigo NUMERIC PRIMARY KEY,
   nombre TEXT,
   caracter TEXT,
   creditos NUMERIC
);

--Tabla matriculas:
CREATE TABLE matriculas(
   carnet_estu NUMERIC,
   codigo_asig NUMERIC,
   nota NUMERIC,

   PRIMARY KEY (carnet_estu, codigo_asig),

   FOREIGN KEY (carnet_estu)
      REFERENCES estudiantes(carnet)
```

Cuestión 3: Mostrar las estadísticas obtenidas en este momento para cada tabla. ¿Qué se almacena? ¿Son correctas? Si no son correctas, ¿cómo se pueden actualizar?

PONER LAS ESTADISTICAS Y DEMAS AQUI

Las estadísticas almacenadas por PostgreSQL contienen información sobre la distribución de los valores de cada columna, incluyendo valores más frecuentes, histogramas y número estimado de valores distintos.
Estas estadísticas son utilizadas por el optimizador de PostgreSQL para decidir el mejor plan de ejecución de las consultas.

Si las estadisticas no son correctas, es posible que los datos aun no se hayan actualizado, para esto utilizamos el comando ANALYZE para así actualizar las estadísticas y garantizar que las consultas se optimicen correctamente.
Siempre es recomendable ejecutarlo tras una carga de datos, especialmente si es masiva.

Cuestión 4: Aplicar el comando EXPLAIN a una consulta que obtenga el número de alumnos con créditos de menos de 100 créditos ECTS. ¿Son correctos los resultados del comando EXPLAIN? ¿Por qué? Comparar con lo que se obtendría con el procedimiento visto en teoría obteniendo las estadísticas de postgres.

El comando EXPLAIN muestra el plan de ejecución que postgre utilizará para ejecutar una consulta.
-Codigo del comando:

```
EXPLAIN
SELECT COUNT(*)
FROM estudiantes
WHERE creditos < 100;
```

-Salida del comado explain:

```
Aggregate  (cost=6815.67..6815.68 rows=1 width=8)
  ->  Seq Scan on estudiantes  (cost=0.00..6510.00 rows=122269 width=0)
        Filter: (creditos < '100'::numeric)
```

El comando EXPLAIN muestra que PostgreSQL realiza un escaneo secuencial sobre la tabla estudiantes y posteriormente aplica un filtro para seleccionar los estudiantes con menos de 100 créditos.
Finalmente se ejecuta una operación de agregación para calcular el número total de registros que cumplen la condición. Las estimaciones mostradas se basan en las estadísticas almacenadas por PostgreSQL sobre la distribución de los valores de la columna creditos.

COMPARACION CON TEORIA.

Cuestión 5: Aplicar el comando EXPLAIN a una consulta que obtenga el nombre de los alumnos que tienen 150 créditos y además tienen por lo menos 3 asignaturas aprobadas. ¿Son correctos los resultados del comando EXPLAIN? ¿Por qué? Comparar con lo que se obtendría con el procedimiento visto en teoría obteniendo las estadísticas de postgres.

El comando EXPLAIN muestra el plan de ejecución que postgre utilizará para ejecutar una consulta.
-Codigo del comando:

```
EXPLAIN
SELECT e.nombre
FROM estudiantes e
JOIN matriculas m ON e.carnet = m.carnet_estu
WHERE e.creditos = 150 AND m.nota >= 5
GROUP BY e.carnet, e.nombre
HAVING COUNT(m.codigo_asig) >= 3;
```

-Salida del comado explain:

```
HashAggregate  (cost=166004.37..166019.87 rows=413 width=18)
  Group Key: e.carnet
  Filter: (count(m.codigo_asig) >= 3)
  ->  Nested Loop  (cost=0.43..165869.82 rows=26910 width=24)
        ->  Seq Scan on estudiantes e  (cost=0.00..6510.00 rows=1240 width=18)
              Filter: (creditos = '150'::numeric)
        ->  Index Scan using matriculas_pkey on matriculas m  (cost=0.43..128.30 rows=22 width=12)
              Index Cond: (carnet_estu = e.carnet)
              Filter: (nota >= '5'::numeric)
```

El plan de ejecución indica que PostgreSQL:
- Escanea los estudiantes con 150 créditos (Seq Scan)

Cuestión 6: Aplicar el comando EXPLAIN a una consulta que obtenga el nombre de las asignaturas de 10 créditos en los que los alumnos hayan obtenido un 7 de nota y los alumnos tengan un número de 50 créditos. ¿Son correctos los resultados del

comando EXPLAIN? ¿Por qué? Comparar con lo que se obtendría con lo visto en teoría obteniendo las estadísticas de postgres

El comando EXPLAIN muestra el plan de ejecución que postgre utilizará para ejecutar una consulta.
-Codigo del comando:

```
EXPLAIN
SELECT a.nombre
FROM asignaturas a
JOIN matriculas m ON a.codigo = m.codigo_asig
JOIN estudiantes e ON e.carnet = m.carnet_estu
WHERE a.creditos = 10
AND m.nota = 7
AND e.creditos = 50;
```

-Salida del comado explain:

```
Nested Loop  (cost=0.86..167977.94 rows=336 width=13)
 ->  Nested Loop  (cost=0.43..165646.62 rows=4397 width=6)
       ->  Seq Scan on estudiantes e  (cost=0.00..6510.00 rows=1240 width=6)
             Filter: (creditos = '50'::numeric)
       ->  Index Scan using matriculas_pkey on matriculas m  (cost=0.43..128.30 rows=4 width=12)
             Index Cond: (carnet_estu = e.carnet)
             Filter: (nota = '7'::numeric)
 ->  Index Scan using asignaturas_pkey on asignaturas a  (cost=0.43..0.53 rows=1 width=19)
       Index Cond: (codigo = m.codigo_asig)
```

Cuestión 7: Generar los datos solicitados al comienzo de la práctica para la base de datos **MUSICOS** creando un programa para tal fin que deberá de estar en un único fichero y comentado. Pegar el código del fichero en el cuadro de texto que se adjunta a continuación.

```
import random
from datetime import datetime, timedelta

# ==========================
# CONFIGURACIÓN
# ==========================

NUM_MUSICOS = 1_000_000
NUM_GRUPOS = 200_000
NUM_DISCOS = 1_000_000
NUM_CONCIERTOS = 100_000
NUM_ENTRADAS = 24_000_000

GENEROS = [
   "clasica","blues","jazz","rock&roll","gospel","soul",
   "rock","metal","funk","disco","techno","pop",
   "reggae","hiphop","salsa"
]

PAISES = [
   "España","Francia","Alemania","Italia","Portugal","UK",
   "USA","Mexico","Argentina","Brasil","Chile","Canada",
   "Japon","Corea","Australia","Suecia","Noruega",
   "Dinamarca","Holanda","Irlanda"
```

Cuestión 8: Realizar la carga masiva de los datos generados en la cuestión 7 en la base de datos **MUSICOS**. Indicar el proceso seguido y el orden de carga de las tablas, explicando el porqué de dicho orden; y asegurando la consistencia e integridad de los datos cargados. Comparar los tiempos en las tablas implicadas y explicar a qué es debida la diferencia.

Tabla	Tiempo (seg)
Grupo	4 s 940 ms
Conciertos	1 s 257 ms
Musicos	47 s 573 ms
Discos	26 s 776 ms
Canciones	5 m 56 s 755 ms
Grupos_Tocan_Conciertos	3 m 26 s 250 ms
Entradas	10 m 30 s 174 ms

La carga masiva de datos se ha realizado utilizando el comando COPY.

El orden de carga seguido ha sido:
1. Grupo
2. Conciertos
3. Musicos
4. Discos
5. Canciones
6. Grupos_Tocan_Conciertos
7. Entradas

Justificación del orden:
El orden se ha elegido en función de las dependencias de claves foráneas para garantizar la integridad referencial:
-Grupo: No depende de ninguna tabla. Es referenciada por: Musicos, Discos y Grupos_Tocan_Concierto.
-Conciertos: No depende de ninguna tabla. Es referenciada por: Entradas y Grupos_Tocan_Concierto.
-Musicos: Depende de Grupo.
-Discos: Depende de Grupo.
-Canciones: Depende de Discos.
-Grupos_Tocan_Conciertos: Depende de Grupo y Conciertos
-Entradas: Depende de Conciertos.

Las tablas que mas tardan son: Canciones y Entradas
Las tablas que menos tardan son: Grupo y Conciertos

Las diferencias en los tiempos de carga se deben principalmente al volumen de datos de cada tabla, al tamaño de los registros y a la existencia de restricciones de integridad referencial.
Las tablas con mayor número de filas, como Entradas y Canciones, presentan los mayores tiempos debido al elevado coste de escritura en disco y a la verificación de claves foráneas. Además, tablas con mayor número de atributos o claves primarias compuestas incrementan el tiempo de carga debido al mayor coste de almacenamiento e indexación.

A partir de este momento en adelante, se deben de realizar las siguientes cuestiones con la base de datos que tiene la integridad referencial activada. Es obligatorio y queda prohibido cambiar la integridad referencial de la base de datos.

Cuestión 9: Realizar una consulta SQL que muestre el porcentaje de músicos que realizan conciertos en España teniendo entradas cuyo precio varía entre 20 y 50 euros, y además tienen discos de género 'rock' con alguna canción de más de 3 minutos, y son grupos de más de 3 componentes. Dibujar el diagrama con el resultado del comando EXPLAIN en forma de árbol de álgebra relacional. Explicar la información obtenida en el plan de ejecución de postgreSQL. Comparar el árbol obtenido por nosotros al traducir la consulta original al álgebra relacional y el que obtiene postgreSQL. Comentar las posibles diferencias entre ambos árboles.

Obtener el plan de ejecución con el resultado del comando EXPLAIN. Explicar la información obtenida en el plan de ejecución de postgreSQL. Comparar el árbol obtenido por nosotros al traducir la consulta original al álgebra relacional y el que obtiene postgreSQL. Comentar las posibles diferencias entre ambos árboles.

Consulta SQL creada, tiempo de ejecución y resultado obtenido:

Resultado comando EXPLAIN

Comentarios y explicaciones.

Cuestión 10: Usando PostgreSQL, y a raíz de los resultados de la cuestión anterior, ¿qué acciones realizaría para mejorar el rendimiento de la consulta sin cambiar el código SQL y por qué? Obtener la información pedida de la cuestión 9 y explicar los resultados. Obtener el plan de ejecución con el resultado del comando EXPLAIN. Comentar los resultados obtenidos y comparar con la cuestión anterior.

Consulta SQL creada, tiempo de ejecución y resultado obtenido:

Resultado comando EXPLAIN

Comentarios y explicaciones.

Cuestión 11: Usando PostgreSQL, borre el 30% de los músicos almacenados de manera aleatoria y todos sus datos relacionados de la manera más eficiente posible, ¿cuál ha sido el proceso seguido? ¿Y el tiempo empleado en el borrado? Prohibido modificar la Integridad Referencial.

Cuestión 12: Ejecute la consulta que pide los datos de la cuestión 9 de nuevo. Obtener el plan de ejecución con el resultado del comando EXPLAIN. Comparar con los resultados anteriores.

Consulta SQL creada, tiempo de ejecución y resultado obtenido:

Resultado comando EXPLAIN

Comentarios y explicaciones.

Cuestión 13: ¿Qué optimización/mejoras de la BD propondría para mejorar los resultados de dicho plan sin modificar el código SQL de la consulta? ¿Por qué? No implementarlo ahora.

Cuestión 14: Usando PostgreSQL, lleve a cabo las operaciones propuestas en la cuestión anterior y ejecute el plan de ejecución de la consulta que pide los datos de la cuestión 9. Obtener el plan de ejecución con el resultado del comando EXPLAIN. Compare los resultados del plan de ejecución con los de los apartados anteriores. Coméntelos.

Consulta SQL creada, tiempo de ejecución y resultado obtenido:

Resultado comando EXPLAIN

Comentarios y explicaciones.

Cuestión 15: A partir de lo visto y recopilado en toda la práctica. Describir y comentar cómo es el proceso de procesamiento y optimización que realiza PostgreSQL en las consultas del usuario.

Bibliografía

PostgreSQL (17)

- Capítulo 14: Performance Tips.
- Capítulo 19: Server Configuration.
- Capítulo 15: Parallel Query.
- Capítulo 24: Routine Database Maintenance Tasks.
- Capítulo 51: Overview of PostgreSQL Internals.
- Capítulo 69: How the Planner Uses Statistics.
- https://pgtune.leopard.in.ua/
- https://explain.dalibo.com/